## Einführung in die Stochastik - Mitschrieb

## $Vor lesung \ im \ Wintersemester \ 2011/2012$

Sarah Lutteropp

20. Oktober 2011

# Inhaltsverzeichnis

1	$\mathbf{Des}$	skriptive Statistik
	1.1	Der Grundraum
	1.2	Absolute und relative Häufigkeit
	1.3	Histogramm
	1.4	Lagemaße
	1.5	Streuungsmaße
	1.6	Empirischer Korrelationskoeffizient
2		ignisse und Zufallsvariablen
	2.1	Definition
	2.2	Beispiele
	2.3	Bemerkung (Mengentheoretische Operationen)
	2.4	Definition
	2.5	Definition
	2.6	Definition
	2.7	Bemerkungen (Rechenregeln für Indikatorfunktionen)
	2.8	Definition

## Vorwort

Dies ist ein Mitschrieb der Vorlesung "Einführung in die Stochastik" vom Wintersemester 2011/2012 am Karlsruher Institut für Technologie, die von Herrn Prof. Dr. Günther Last gehalten wird.

## Kapitel 1

# Deskriptive Statistik

### 1.1 Der Grundraum

 $\emptyset \neq \Omega = \text{Grundraum (Grundgesamtheit, Merkmalsraum, Stichprobenraum)}$ Annahme:  $\Omega$  ist diskret(endlich oder abzählbar unendlich) (Häufig  $\Omega \subseteq \mathbb{R}$ )

### 1.2 Absolute und relative Häufigkeit

$$x_1,\ldots,x_n\in\Omega$$
 ("Daten")  $h(\omega)=card\left\{j\in\{1,\ldots,n\}\colon x_j=\omega\right\},\omega\in\Omega$ , absolute Häufigkeit von  $\omega$ 

Bemerkung 
$$\sum_{\omega \in \Omega} h(\omega) = n$$

**Definition**  $\frac{1}{n}h(\omega)$  = relative Häufigkeit von  $\omega$   $h(A) = card\{j \in \{1, \dots, n\}: x_j \in A\}, A \subset \Omega$  = absolute Häufigkeit von A,  $\frac{1}{n}h(A)$  = relative Häufigkeit von A

## 1.3 Histogramm

$$x_1, \dots, x_n \in \mathbb{R}, b_1 < b_2 < \dots < b_s \text{ mit } b_1 \leq \min_{1 \leq i \leq n} x_i, b_s > \max_{1 \leq i \leq n} x_i$$
  
TODO: BILD  
 $d_j(b_{j+1} - b_j) = h([b_j, b_{j+1})) = card\{i \in \{1, \dots, n\} : b_j \leq x_i < b_{j+1}\}$ 

## 1.4 Lagemaße

**Definition** Ein **Lagemaß** ist eine Abbildung  $l : \mathbb{R}^n \to \mathbb{R}$  mit

$$l(x_1 + a, \dots, x_n + a) = l(x_1, \dots, x_n) + a$$

<sup>&</sup>quot;Verschiebungskovarianz".  $x_1, \ldots, x_n, a \in \mathbb{R}$ 

1.4 Lagemaße 4

#### 1.4.1 Arithmetisches Mittel

$$x_1, \ldots, x_n \in \mathbb{R}, \bar{x} := \frac{1}{n} \sum_{j=1}^n x_j$$
 "Schwerpunkt der Daten"

Fakt 
$$\sum_{i=1}^{n} (x_i - t)^2 \xrightarrow{t} \text{Min}$$

Lösung:  $t = \bar{x}$ 

"Prinzip der kleinsten Quadrate"

**Beweis** 
$$\frac{1}{n}\sum_{j=1}^{n}(x_j-t)^2=t^2-2\bar{x}t+\frac{1}{n}\sum_{j=1}^{n}x_j^2=(t-\bar{x})^2+\frac{1}{n}\sum_{j=1}^{n}x_j^2-(\bar{x})^2$$

#### 1.4.2 Median, Quantile

$$x_1, \ldots, x_n \in \mathbb{R} \Rightarrow x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$$
 geordnete Stichprobe

#### Definition

$$x_{1/2} := \begin{cases} x_{(\frac{n+1}{2})} & \text{, falls } n \text{ ungerade} \\ \frac{1}{2}(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}) & \text{, falls } n \text{ gerade} \end{cases}$$

heißt **Median** von  $x_1, \ldots, x_n$ .

Fakt 
$$\sum_{j=1}^{n} |x_j - x_{1/2}| = \min_{t} \sum_{j=1}^{n} |x_j - t| Übungsaufgabe$$

**Bemerkung** Der Median ist "robust" gegenüber "Ausreißern". Ist etwa  $x_1 = \ldots = x_9 = 1$  und  $x_{10} = 1000(n = 10)$ , so gilt  $\bar{x} = 100, 9, x_{1/2} = 1$ 

**Definition** Für 0 heißt

$$x_p := \begin{cases} x_{(\lfloor n \cdot p + 1 \rfloor)} & \text{, falls } n \cdot p \notin \mathbb{N} \\ \frac{1}{2} (x_{(n \cdot p)} + x_{(n \cdot p + 1)}) & \text{, falls } n \cdot p \in \mathbb{N} \end{cases}$$

**p-Quantil** von  $x_1, \ldots, x_n$ .

**Interpretation** Mindestens  $p \cdot 100\%$  der Daten liegen links von  $x_p$  und mindestens  $(1-p) \cdot 100\%$  liegen rechts von  $x_p$ .  $x_{1/4}$  = unteres Quartil,  $x_{3/4}$  = oberes Quartil

#### 1.5Streuungsmaße

**Definition** Eine Abbildung  $\sigma: \mathbb{R}^n \to \mathbb{R}$  mit

$$\sigma(x_1 + a, \dots, x_n + a) = \sigma(x_1, \dots, x_n)$$
 (Translationsinvarianz)

heißt Streuungsmaß.

#### 1.5.1Empirische Varianz

$$s^2 := \frac{1}{n-1} \sum_{j=1}^n (x_j - \bar{x})^2 =$$
 empirische Varianz von  $x_1, \dots, x_n$ 

### 1.5.2 Empirische Standardabweichung

 $s := +\sqrt{s^2} =$  empirische Standardabweichung von  $x_1, \ldots, x_n$ 

#### 1.5.3Spannweite

$$x_{(n)}-x_{(1)}=$$
 Spannweite von  $x_1,\ldots,x_n$ 

#### 1.5.4 Quartilsabstand

 $x_{(3/4)-x_{(1/4)}} = \mathbf{Quartilsabstand} \text{ von } x_1, \dots, x_n$ 

## Empirischer Korrelationskoeffizient

$$(x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R}^2$$
 TODO: BILD  
Gesucht: Gerade  $y = a + b \cdot x$  so, dass

$$(*)$$
  $\sum_{j=1}^{n} (y_j - a - bx_j)^2 \stackrel{a,b}{\to} \text{Min}$ 

**Definition** 
$$\sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \ \sigma_y^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

$$\sigma_{xy} = \frac{1}{n} \sum_{j=1}^{n} (x_j - \bar{x})(y_j - \bar{y})$$
 empirische Kovarianz  $\sigma_x^2 > 0, \sigma_y^2 > 0.$ 

Lösung von (\*): 
$$b^* = \frac{\sigma_{xy}}{\sigma_{x^2}}, a^* = \bar{y} - b^* \cdot \bar{x}$$

$$\min_{\substack{a,b \ a,b}} \sum_{j=1}^{n} (y_j - a - bx_j)^2 \stackrel{!}{=} \min_{\substack{b \ b}} \sum_{j=1}^{n} (y_i - \bar{y} - b(x_j - \bar{x}))^2 = \dots$$

"lineare Regression"

Einsetzen von  $a^*$  und  $b^*$  in die Zielfunktion:

$$0 \le \sum_{j=1}^{n} (y_j - a^* - b^* x_j)^2 = \dots = n\sigma_y^2 (1 - (\frac{\sigma_{xy}}{\sigma_x \sigma_y})^2)$$

Definition  $r_{xy}:=rac{\sigma_{xy}}{\sigma_x\sigma_y}$  heißt empirischer Korrelationskoeffizient (Pearson).

Folgerung  $|r_{xy}| \le 1$ Es gilt  $r_{xy} = \pm 1 \Leftrightarrow$  Punktewolke liegt exakt auf der Geraden  $y = a^* + b^*x$ . Dabei ist  $b^* > 0$ , falls  $r_{xy} = 1$  und  $b^* < 0$ , falls  $r_{xy} = -1$ .

Dieser empirische Korrelationskoeffizient ist ein Maß für die (affin) lineare  $Abh \ddot{a}ngigkeit zwischen den x_j und den y_j$ .

## Kapitel 2

# Ereignisse und Zufallsvariablen

### 2.1 Definition

Gegeben sei eine Grundmenge  $\Omega$ . Die Elemente von  $\Omega$  heißen **Elementarereignisse**. Teilmengen von  $\Omega$  heißen **Ereignisse**. (Idee:  $\omega \in \Omega$  ist Ausgang eines zufälligen Versuchs.)

**Interpretation** Ein Ereignis  $A \subset \Omega$  "tritt ein", wenn  $\omega \in A$ .

### 2.2 Beispiele

- (i) (Münzwurf)  $\Omega = \{0, 1\} (\text{oder } \Omega = \{W, Z\})$
- (ii) (m Münzwürfe)  $\Omega = \{0,1\}^m (A = \{\omega = (\omega_1,\ldots,\omega_m): \sum_{j=1}^m \omega_j \geq k\} \text{ Ereignis })$
- (iii) Werfen von 2 Würfeln  $\Omega = \{1, \dots, 6\}^2$
- (iv) Brownsche Bewegung (TODO: BILD) Bewegung eines Blütenpollens in einer Flüssigkeit  $\Rightarrow$  Zukunftsmusik  $\Omega = C([0,1], \mathbb{R}^2)$

## 2.3 Bemerkung (Mengentheoretische Operationen)

```
Seien A, B, A_1, A_2, \ldots \subset \Omega.

A \cap B = \{\omega \in \Omega : \omega \in A \text{ und } \omega \in B\} = \text{"A und B treten ein"}

A \cup B = \text{"A oder B treten ein"}

\bar{A} \equiv A^c := \Omega \setminus A = \{\omega \in \Omega : \omega \notin A\} = \text{"A tritt nicht ein"}
```

2.4 Definition 8

 $A \backslash B = A \cap B^c \hat{=}$  "A tritt ein, aber nicht B"  $A \subset B \hat{=}$  "wenn A, dann B"  $\emptyset \hat{=}$  "unmögliches Ereignis"  $\Omega \hat{=}$  "sicheres Ereignis"

**Abkürzung**  $AB = A \cap B$ 

### 2.4 Definition

Eine Abbildung  $X: \Omega \to \mathbb{R}$  heißt (reelle) **Zufallsvariable**. Für  $\omega \in \Omega$  heißt  $X(\omega)$  **Realisierung** der Zufallsvariable zu  $\omega$ .

**Idee** Mit  $\omega \in \Omega$  bekommt auch  $X(\omega)$  einen zufälligen Charakter.

**Definition** 
$$X^{-1} \colon \mathcal{P}(\mathbb{R}) \to \mathcal{P}(\Omega) = \{A \colon A \in \Omega\}$$
 ist definiert durch  $X^{-1}(A) = \{\omega \in \Omega \colon X(\omega) \in A\}$  ("Urbild von A unter X")

### Bemerkung

• 
$$X^{-1}(A \cap B) = X^{-1}(A) \cap X^{-1}(B), A, B \subset \mathbb{R}$$

• 
$$X^{-1}(A \cup B) = X^{-1}(A) \cup X^{-1}(B)$$

• 
$$X^{-1}(\bigcup_{j=1}^{\infty} A_j) = \bigcup_{j=1}^{\infty} X^{-1}(A_j)$$

• 
$$X^{-1}(\bigcap_{j=1}^{\infty} A_j) = \bigcap_{j=1}^{\infty} X^{-1}(A_j)$$

**Vereinbarung** Es sei X eine Zufallsvariable und  $t \in \mathbb{R}$ . Wir setzen

- $\{X = t\} := \{\omega \colon X(\omega) = t\} (= X^{-1}(t))$
- $\{X \ge t\} := \{\omega \colon X(\omega) \ge t\}$

### 2.5 Definition

Sind X, Y Zufallsvariablen, so definiert man

• 
$$(X + Y)(\omega) = X(\omega) + Y(\omega)$$

• 
$$(X - Y)(\omega) = X(\omega) - Y(\omega)$$

• 
$$(X \cdot Y)(\omega) = X(\omega) \cdot Y(\omega)$$

2.6 Definition 9

 $\omega \in \Omega,$ neue Zufallsvariablen  $X+Y, X-Y, X\cdot Y$ analog für  $a \in \mathbb{R}$ 

- $aX(\omega) = a \cdot (X(\omega))$
- $\min(X, Y) = (X \wedge Y)(\omega) := \min\{X(\omega), Y(\omega)\}\dots$

### 2.6 Definition

Sei  $A \subset \Omega$ . Die Funktion  $1_A : \Omega \to \mathbb{R}$  ist definiert durch

$$1_A(\omega) = \begin{cases} 1 & \text{, falls } \omega \in A \\ 0 & \text{, falls } \omega \notin A \end{cases}$$

und heißt Indikatorfunktion von A.

# 2.7 Bemerkungen (Rechenregeln für Indikatorfunktionen)

- $1_{\emptyset} \equiv 0$
- $1_{\Omega} \equiv 1$
- $(1_A)^2 = 1_A$
- $1_{A^c} = 1 1_A$
- $1_{A \cap B} = 1_A \cdot 1_B$
- $1_{A \cup B} = 1_A + 1_B 1_{A \cap B}$
- $A \subset B \Leftrightarrow 1_A \leq 1_B$
- $1_{A \wedge B} = |1_A 1_B|$

### 2.8 Definition

Seien  $A_1, \ldots, A_n \subset \Omega$ . Die Zufallsvariable

$$X := \sum_{j=1}^{n} 1_{A_j}$$

heißt Zählvariable oder Indikatorsumme.

2.8 Definition 10

### Bemerkung

- $\{X = 0\} = \{\omega \colon X(\omega) = 0\} = A_1^c \cap \dots A_n^c$
- $\{X=n\}=A_1\cap\ldots\cap A_n$
- $\{X=k\}$  = "genau k der Ereignisse  $A_1,\ldots,A_n$  treten ein" =  $\bigcup_{T\subset\{1,\ldots,n\},|T|=k} (\bigcap_{j\in T} A_j\cap\bigcap_{j\notin T} A_j^c) (T\subset\{1,\ldots,n\},|T|=\mathrm{card}\ T=k)$